

摘要

针对光伏功率预测中传感器采集数据失真异常、物理规律利用不足以及深度学习模型缺乏真实物理约束等问题,本文提出一种以渐进物理解锁(PPU)机制与物理引导反转注意力(PGIA)为核心创新的 Transformer 预测框架 PPU-Former。其中,PGIA 将晴空辐照度等 12 个物理先验显式注入 iTransformer 的反转注意力层,使变量间建模倾向于"物理因果"驱动,增加特征间的物理一致性并关注不同特征间的约束性;PPU 则以零初始化的可学习标量作为渐进式解锁模块的门阀,物理状态控制门控(PSG)和天气感知频谱增强(WASE)等增强项随损失逐步融入物理约束网络,使模型在训练初期保持恒等映射、在收敛过程中动态释放物理先验,从而兼顾物理引导效果与训练稳定性。围绕上述核心机制,在 DKASC in 2017–2019 at Site-3A 公开光伏数据集上的预测结果表明,PPU-Former 相较于主流强基线模型, RMSE 与 MAE 分别显著降低 10%与 17%,并能在阴雨、强风等高扰动天气下,保持与理想天气相近的预测精度。消融实验展示了所提 PPU 机制和 PGIA 策略的泛化能力,证明了 PPU-Former 的鲁棒性和准确性。

关键词: 光伏功率预测; 渐进物理解锁; 物理引导反转注意力; iTransformer; 物理先验

第一章 Introduction

随着全球能源结构加速向低碳化、清洁化和可再生化转型,光伏发电因其资源丰富、部署灵活和环境友好等优势,已成为新型电力系统中的重要组成部分[1][2]。在高比例新能源并网背景下,光伏出力的不确定性会直接影响电网调度、备用容量配置、储能控制和电力市场运行[3][4]。由于光伏发电功率受太阳辐照和气象条件影响显著,具有明显的间歇性、波动性和非平稳性,准确的短期光伏功率预测已成为提升新能源消纳能力和保障电网安全稳定运行的关键技术之一[5][6]。

光伏功率变化同时受到确定性物理规律和随机性气象扰动的共同影响。一方面,太阳高度角、晴空辐照度和晴空指数等因素决定了光伏功率变化的基本物理趋势,使功率具有显著的日周期性和辐照驱动特征[7][8]。另一方面,降雨、风速以及传感器采集误差等因素会打破理想晴空条件下的平滑变化过程,引起短时间内的功率突变和非线性波动[9][10]。尤其在阴雨等强扰动天气条件下,光伏功率序列往往表现出更强的波动性和不确定性。因此,光伏功率预测模型不仅需要从历史序列中学习时间依赖关系,还需要合理利用晴空指数和气象状态等物理先验信息,以提升模型在复杂工况下的预测精度与鲁棒性[11]–[14]。

针对光伏功率预测问题,已有研究主要包括物理方法、统计方法、机器学习方法和深度学习方法[6][9]。传统物理方法通常基于太阳辐射传播机理、光伏组件特性和系统运行参数建立预测模型,具有较好的物理可解释性,但往往依赖精确的站点参数和高质量气象输入,且建模过程复杂,难以灵活适应实际场景中的多源扰动[11][12]。统计方法如 ARIMA 等能够刻画一定的线性时间相关性,但在面对光伏功率序列中普遍存在的非线性、非平稳和突变特征时,预测能力相对有限[15]。机器学习方法如支持向量回归(SVM)和随机森林(RF)等在一定程度上提升了非线性映射能力,但其性能通常依赖人工特征工程和输入变量选择,难以充分挖掘长时间序列中的深层动态关系[16][17]。近年来,卷积神经网络(CNN)、循环神经网络(RNN)、长短期记忆网络(LSTM)以及混合深度学习模型被广泛应用于超短期和短期光伏功率预测,并取得了较好的预测效果[18][19]。然而,这类深度学习模型大多仍以数据驱动式学习为主,对光伏发电过程中的物理机理利用不足,在复杂天气、异常扰动和跨时段分布变化场景下仍可能出现泛化能力下降的问题。

近年来, Transformer 及其变体在时间序列预测领域表现出较强的长序列建模能力[20]。在高效长序列建模方面, Zhou 等人在 2021 年提出 Informer 模型, 通过 ProbSparse self-attention、自注意力蒸馏和生成式解码机制降低了长序列预测的计算复杂度, 为长时间跨度时间序列预测提供了高效建模框架[21]。在光伏功率预测领域, Cao 等人在 2023 年提出 ISL-LSTM-Informer 模型, 通过改进 Stacking 集成策略将 LSTM 与 Informer 结合, 提升了多时间尺度光伏功率预测的准确性和鲁棒性[22]。在序列分解建模方面, Wu 等人在 2021 年提出 Autoformer 模型, 将序列分解机制嵌入 Transformer 内部, 并利用 Auto-Correlation 机制捕获周期性依赖关系, 从而提高了长期时间序列预测性能[23]。在此基础上, Ouyang 等人在 2025 年提出 SG-Deep-Autoformer, 将季节分布分析与分解优化策略引入短期光伏功率预测任务, 增强了模型对季节变化和天气扰动的适应能力[24]。在频域增强建模方面, Zhou 等人在 2022 年提出 FEDformer 模型, 将季节—趋势分解结构与频域增强机制引入 Transformer, 提高了长期时间序列预测的效率和精度[25]。随后, Wen 等人在 2024 年提出 RAD-FEDformer 模型, 在 FEDformer 基础上引入相关性放大模块和多层感知机结构, 将地理相关信息嵌入多站点光伏预测过程, 增强了模型对空间相关性和长序列依赖的建模能力[26]。Nie 等人在 2023 年提出 PatchTST 模型, 通过子序列级 patch 划分和通道独立建模策略, 保留局部时间语义并降低长历史窗口下的注意力计算开销, 从而提升了长期时间序列预测性能[27]。Wu 等人在 2023 年提出的 TimesNet 模型则从多周期二维变化建模角度提升复杂时序表示能力[28]。进一步地, Liu 等人在 2026 年提出 DWafusion-Net, 通过异常感知与天气感知融合策略, 提升了复杂天气条件下光伏功率预测的鲁棒性[29]。这些方法推动了 Transformer 类模型及其变体在时间序列预测中的应用。相关研究表明, 将物理知识与数据驱动模型结合, 有助于提升光伏功率预测的精度、泛化能力和可解释性[30][31]。对于光伏功率预测任务而言, 历史功率、辐照度、温度、风速和其他气象变量之间存在较强耦合关系, 而 iTransformer 能够更直接地刻画多变量时间序列中的跨变量依赖关系, 为复杂气象条件下的光伏功率预测提供了有效建模基础[32]。因此本文将物理参量注入到 iTransformer 模型中, 从而有效提升多步光伏功率预测性能。

然而, 光伏物理先验如何与深度模型内部机制有效结合, 仍有进一步研究空间。光伏功率序列在昼夜和不同辐照条件下表现出明显差异, 夜间或低辐照阶段容易出现残留噪声和无效波动, 若这些信号不经筛选地注入模型, 会干扰辐照类变量对功率变化的有效表征。晴天条件下, 功率变化通常具有较稳定的周期结构; 阴雨、过云等复杂天气下, 序列中会出现更多突变和高频扰动, 单一时域特征提取方式难以同时适应这两类变化模式。虽然 iTransformer 模型擅长捕获长序列依赖, 但对变量内部的局部短时连续性刻画仍不充分。更关键的是, 现有物理融合方法多将太阳几何、晴空指数或气象变量作为附加输入, 物理先验并未真正参与模型内部的变量交互建模, 因而难以直接引导注意力机制学习更加符合光伏机理的变量关系。若进一步将物理约束直接强加到深度网络中, 又可能在训练初期影响骨干模型的稳定优化。由此可见, 在保持 iTransformer 数据建模能力的基础上, 从输入表征、频域特征、局部时序和变量注意力等层面稳定引入光伏物理先验, 是本文需要解决的关键问题。

为解决上述问题, 本文提出 A short-term PV active power forecasting framework based on an incremental physical unlocking mechanism and physically guided attention reversal (PPU-Former)。该方法以 iTransformer 为基础骨干, 在保持单流串行预测结构的前提下, 从输入幅值、频域特征、局部时序依赖和变量级注意力四个层面对光伏物理先验进行逐步注入。首先, 本文在数据清洗与特征融合阶段, 将原始气象观测变量与由天文几何、晴空辐射和晴空指数等构造出的物理变量进行统一组织, 形成固定维度的多变量时间序列输入。其次, 在模型前端设计物理状态门控模块 PSG, 根据样本物理状态对辐照类通道进行软门控调节, 以抑制夜间或低辐照阶段的标准化残留噪声。随后, 引入天气感知频谱增强模块 WASE, 根据不同天气状态

对频域成分进行自适应滤波,使模型能够同时关注晴天条件下的平滑周期结构和阴雨、过云条件下的高频突变信息。此外,本文加入轻量级深度可分离卷积模块 DSC,以增强每个变量内部的局部短时连续性,弥补纯注意力结构在局部时序建模方面的不足。

本文的核心创新在于构建物理引导的变量关系建模策略(PGIA)。不同于仅在输入端拼接物理特征的方式,所提出的 PGIA 将物理状态信息引入 iTransformer 的反转注意力过程,使模型在学习变量相关性的同时,能够受到太阳几何、晴空程度和天气扰动等物理先验的引导。通过这种方式,模型对辐照度、温度、风速等变量和历史功率之间关系的刻画不再完全依赖数据共现,而是更加符合光伏发电过程中的物理规律,从而增强预测结果的可靠性和可解释性。与此同时,本文还设计了渐进物理解锁机制(PPU),使物理增强模块在训练过程中逐步发挥作用,避免强先验过早介入对骨干模型造成扰动。该设计既保留了 iTransformer 的数据建模能力,又使物理先验能够以更加稳定和可控的方式参与预测过程。

本文基于澳大利亚 DKASC Yulara Site-3A 公开光伏数据集开展实验验证。该站点属于澳大利亚 Yulara Solar System,公开提供光伏系统运行与气象相关数据,其中 Site-3A 对应 Sails in the Desert - 1 系统。本文采用小时级多变量时间序列数据完成短期光伏有功功率点预测任务,并设置多种数据划分方式以检验模型在不同时间分布下的泛化能力。实验中,本文将所提 PPU-Former 与多种经典机器学习模型、深度学习模型以及主流 Transformer 类时间序列预测模型进行系统对比,并通过模块级消融实验分别分析 PSG、WASE、DSC、PGIA 和 PPU 对预测性能的贡献。实验结果表明,所提方法能够有效提升短期光伏功率预测精度,并在复杂天气和高扰动工况下表现出更强的鲁棒性。

综上所述,本文的主要贡献如下:

1.提出物理引导反转注意力机制 PGIA。

针对原始 iTransformer 在变量级注意力建模中缺乏物理约束的问题,本文在 softmax 之前的注意力 logits 中引入由物理状态摘要向量驱动的可学习加性偏置,使模型能够根据昼夜状态、晴空程度和天气扰动动态调整变量间注意力分布,从而降低伪相关影响,增强变量交互关系的物理一致性。

2.提出渐进物理解锁机制 PPU,提高物理先验注入的稳定性。

本文通过零初始化门控标量或零初始化偏置层末层,使各物理增强模块在训练初期保持恒等映射,保证模型初始状态等价于 vanilla iTransformer。随着训练推进,物理增强项在优化过程中被逐步激活,从而避免强先验直接注入带来的训练不稳定问题,并为消融实验提供更清晰的解释依据。

3.提出一种面向短期光伏功率预测的物理先验增强 iTransformer 框架。

本文以 iTransformer 为骨干模型,结合光伏发电中的太阳几何、晴空辐射、晴空指数和气象状态等物理信息,构建 PPU-Former 预测框架。该框架在保持单流串行结构的基础上,将物理先验分别注入输入幅值层、频域增强层、局部时序层和变量注意力层,从而兼顾数据驱动建模能力与物理可解释性。

4.设计天气感知频谱增强与局部时序补强模块。

本文提出 WASE 模块,对不同天气状态下的频域特征进行自适应调节,以协调晴天平滑周期结构和阴雨过云条件下的高频突变信息;同时引入轻量级深度可分离卷积 DSC,补强每个变量内部的短时连续性建模能力,提升模型对局部波动和快速变化过程的响应能力。

本文其余部分安排如下:第二部分介绍相关工作,包括光伏功率预测方法、Transformer 时间序列预测模型以及物理先验融合方法。第三部分详细阐述所提出的 PPU-Former 模型结构与各模块设计。第四部分介绍数据集、实验设置、对比模型和评价指标。第五部分给出实验结果、消融分析、鲁棒性分析和可解释性讨论。最后,第六部分总结全文并展望未来研究方向。

第二章 Methodology

本文提出的光伏功率预测模型 PPU-Former (Progressive Physics Unlocking Transformer) 整体设计与数据流如图 1 所示。该模型旨在解决短期光伏功率预测中低辐照阶段非物理残留干扰、复杂天气下频谱变化模式不一致、局部变量之间短期依赖刻画不足,以及物理先验难以直接参与变量级交互建模等问题。结构上,PPU-Former 以 iTransformer 的反转注意力框架为基础,融合物理状态门控、天气感知频谱增强、局部时序补强、物理引导反转注意力和渐进式物理解锁策略,使光伏物理先验能够从输入表征、频域响应、局部时序和跨变量注意力多个层面参与预测过程。整个模型包括五个核心组成部分:物理状态门 PSG 在幅值层依据日照状态抑制夜间辐照通道的伪信号、气象感知频谱增强 WASE 在频率层做样本依赖的自适应滤波、深度可分离卷积 DSC 在局部时域层补偿反转注意力丢失的短程信息、物理引导反转注意力 PGIA 在 backbone 的注意力计算中加入由物理摘要驱动的可学习偏置,以及将上述模块统一为“恒等起步、按需解锁”的渐进式物理解锁策略 PPU。本章将依次对上述模块进行详尽介绍。




Figure 1. The overall structure of PPU-Former

2.1 PPU-Former 整体架构

PPU-Former 模型构建在 iTransformer (ICLR 2024) 反转注意力 backbone 的基础上,采用单流串行结构,分别在幅值、频率、局部时域与注意力四个抽象层级注入物理先验,再以一套统一的零初始化机制协同部署。首先,原始气象观测变量、目标变量 AP 以及由太阳几何、晴空辐照和晴空指数等构造得到的物理先验变量共同组成输入张量。随后,输入张量依次通过 PSG、WASE 和 DSC 三个保形输入重构模块。PSG 在幅值层根据昼夜状态和辐照物理状态对辐照类通道进行软调节,以降低低辐照阶段非物理残留的影响。WASE 在频域层根据样本上下文生成自适应滤波响应,以适应晴天周期结构和复杂天气短时扰动之间的差异。DSC 在局部时域层对每个变量进行轻量卷积增强,用于补充变量内部的短时连续性和局部爬坡信息。

经过输入重构后,序列进入 iTransformer backbone。模型首先通过 RevIN-lite 和 Inverted

Embedding 将每个变量的历史序列映射为变量级 token，然后送入 PGIA encoder。PGIA 在标准反转注意力的 pre-softmax logits 中加入由物理摘要向量生成的可学习偏置，使变量间注意力分配能够根据当前样本的昼夜状态、晴空程度和天气扰动进行调整。最后，编码后的变量表示通过线性预测头映射为未来 H 个时间步的有功功率预测结果。

为避免多个物理增强模块在训练初期同时扰动 backbone，PPU-Former 将 PSG、WASE、DSC 和 PGIA 统一部署在 PPU 策略下。该策略通过零初始化门控标量或零初始化偏置层，使新增物理模块在训练初始阶段等价于恒等映射或零偏置状态；随着训练过程中预测损失的反向传播，物理增强项逐步参与模型优化，从而提高训练稳定性和模块贡献的可解释性。

Algorithm 1 Procedure of PPU-Former

Input: Multivariate PV sequence X

Output: Multi-step active power prediction $\hat{Y}$

- 1: Construct the input tensor by combining meteorological variables, historical active power, and physical prior variables.
- 2: Apply PSG to adjust irradiance-related channels according to solar and irradiance states.
- 3: Apply WASE to obtain sample-adaptive spectral responses under different weather conditions.
- 4: Apply DSC to enhance local temporal continuity within each variable.
- 5: Normalize the reconstructed sequence and generate variable tokens through inverted embedding.
- 6: Feed variable tokens into the PGIA encoder and inject physics-guided bias into attention logits.
- 7: Decode the encoded representations through the prediction head.
- 8: Compute the forecasting loss on Active_Power and update all trainable parameters.

2.2 Physics-aware input reconstruction

PPU-Former 在输入端通过 PSG、WASE 和 DSC 对原始序列进行物理感知重构。三者分别作用于幅值层、频域层和局部时域层，对应光伏预测中的三个具体问题：低辐照阶段非物理残留、复杂天气下频谱结构差异，以及变量内部短时连续性不足。与直接拼接物理变量不同，输入重构模块并不改变预测任务的数据流形式，而是在保持张量形状一致的前提下，对输入序列进行物理一致性增强。

2.2.1 Physics State Gate(PSG)

在光伏功率预测中辐照相关变量通常与太阳高度、昼夜状态和晴空条件密切相关。夜间或低太阳高度角阶段，辐照类通道理论上应接近零，但实际观测和标准化处理后仍可能存在小幅非零残留。这类残留虽然数值较小，却可能在多变量建模中被误认为有效相关信号，从而干扰模型的学习。为降低这种非物理残留对建模的影响，本文设计物理状态门控模块 PSG，根据可解析的物理状态为辐照相关通道生成软门控权重，其结构如图 2 所示。

原始多变量光伏输入序列记为 $X^{(0)} \in \mathbb{R}^{B \times L \times N}$ ，其中 B 表示 batch size， L 表示历史输入窗口长度， N 表示输入变量总数。PSG 首先从 $X^{(0)}$ 中提取物理先验通道，得到物理状态张量

$\Phi = X_{:, :, \mathcal{I}_\Phi}^{(0)}$ ，并通过两层 MLP 生成辐照相关通道的门控权重：

$$g = \sigma(\text{Gelu}(W_2 \Phi + b_2)) \in (0,1)^{B \times L \times |\mathcal{I}_R|} \quad (1)$$

其中， Φ 表示用于生成门控权重的物理先验张量； $\mathcal{I}_\Phi$ 表示物理先验通道在变量轴上的索引

集合; g 表示 PSG 生成的门值张量; $\sigma(\cdot)$ 表示 sigmoid 激活函数; $\text{GELU}(\cdot)$ 表示 GELU 非线性激活函数; J_R 表示辐照相关通道索引集合; $|J_R|$ 表示辐照相关通道数量; W_1 和 W_2 为可学习权重矩阵; b_1 和 b_2 为可学习偏置项。

在初始化阶段, W_2 权重零初始化, b_2 初始化为 3.0, 使门控值起点接近 $\sigma(3) \approx 0.95$ 。因此, PSG 在训练初始阶段近似处于“打开”状态, 不会直接压制辐照通道。

为将 g 扩展到全 N 个变量通道, 并保证非辐照通道保持原始输入形式, 构造缩放矩阵 $S \in \mathbb{R}^{B \times L \times N}$, 其元素为:

$$S_{::,n} = \begin{cases} g_{::,k}, & n = J_R[k] \\ 1, & \text{otherwise} \end{cases}, \quad (2)$$

其中, $S_{::,n}$ 表示缩放矩阵在第 n 个变量通道上的取值。 $g_{::,k}$ 表示第 k 个辐照通道对应的门值。 n 表示变量通道索引。 $J_R[k]$ 表示辐照通道索引集合中的第 k 个元素。当 n 属于辐照相关通道时, S 取对应门值; 当 n 不属于辐照相关通道时, S 取 1, 从而使非辐照通道保持不变。

最终, PSG 采用乘性残差形式对输入进行物理状态调节:

$$X^{(1)} = X^{(0)} \odot [1 + \gamma_{\text{psg}}(S - 1)], \quad (3)$$

其中, $X^{(1)}$ 表示 PSG 输出张量。 $X^{(0)}$ 表示 PSG 输入张量。 $\odot$ 表示逐元素乘法。 $\gamma_{\text{psg}} \in \mathbb{R}$ 表示零初始化的可学习标量。 S 表示由门值扩展得到的缩放矩阵。

当 $\gamma_{\text{psg}} = 0$ 时, 公式 (3) 退化为 $X^{(1)} = X^{(0)}$, PSG 不改变输入序列。随着训练过程中预测损失的反向传播, γ_{psg} 逐步更新, PSG 才开始对辐照通道进行可控调节。该设计避免了人为硬阈值修正造成的信息损失, 同时使辐照变量在进入后续 WASE 和 backbone 之前具有更好的物理一致性。




Figure 2. The structure of Physics State Gate (PSG)

2.2.2 Weather-Aware Spectral Enhancement(WASE)

光伏功率序列在不同天气条件下呈现不同的频谱结构。晴天样本通常具有较稳定的日周期变化, 主要能量集中在低频成分; 阴雨、过云或强风扰动条件下, 辐照和功率会出现更明显的短时波动, 高频成分相对增强。如果模型采用固定的频域响应, 容易在晴天样本中过度放大噪声, 或在扰动天气下忽略短时突变。为此, 本文在 PSG 之后引入天气感知频谱增强模块 WASE, 根据样本上下文动态生成频域滤波权重, 从而实现不同天气状态下的自适应频谱响

应，其结构如图 3 所示。

WASE 的输入为 $X^{(1)} \in \mathbb{R}^{B \times L \times N}$ 。首先，将 $X^{(1)}$ 沿时间维进行实值快速傅里叶变换，得到频域复值表示：

$$Z = \text{rFFT}(X^{(1)\top}) \in \mathbb{C}^{B \times N \times K}, K = \lfloor L/2 \rfloor + 1, \quad (4)$$

其中， Z 表示由 $X^{(1)}$ 变换得到的频域复值张量。 $\text{rFFT}(\cdot)$ 表示实值快速傅里叶变换算子。 $X^{(1)\top}$ 表示将 $X^{(1)}$ 的时间维和变量维互换后的张量。 K 表示频域长度。 $\mathbb{C}$ 表示复数域。 B 、 N 和 L 分别表示 batch size、变量数和历史输入长度。

为使频域响应能够随样本状态变化，WASE 构造样本上下文摘要 $c \in \mathbb{R}^{B \times 3N}$ 。该摘要由每个变量在历史窗口内的均值、标准差和最后一个时间步状态拼接得到：

$$c = [\mu_t(X^{(1)}), \text{std}_t(X^{(1)}), X_{:,L-1,:}^{(1)}] \in \mathbb{R}^{B \times 3N}, \quad (5)$$

其中， c 表示样本上下文摘要向量。 $\mu_t(\cdot)$ 表示沿时间维 L 计算均值。 $\text{std}_t(\cdot)$ 表示沿时间维 L 计算标准差。 $X_{:,L-1,:}^{(1)}$ 表示输入窗口最后一个时间步的变量状态。 $[:, :, :]$ 表示沿最后一维进行拼接。

基于上下文摘要 c ，WASE 通过两个独立的 MLP 分别生成自适应频域滤波器 A 和残差混合门 r ：

$$A = \sigma(\text{MLP}_c(c)) \in (0,1)^{B \times N \times K}, r = \sigma(\text{MLP}_r(c)) \in (0,1)^{B \times N}, \quad (6)$$

其中， A 表示样本自适应频域滤波器。 $\text{MLP}_c(\cdot)$ 表示用于生成频域滤波权重的多层感知机。 r 表示残差混合门。 $\text{MLP}_r(\cdot)$ 表示用于生成残差混合权重的多层感知机。 $A \in (0,1)^{B \times N \times K}$ 表示每个样本、每个变量和每个频率点均有对应滤波系数。 $r \in (0,1)^{B \times N}$ 表示每个样本和每个变量均有对应残差混合权重。

在初始化阶段， MLP_r 的末层权重零初始化，偏置初始化为 3.0，使 r 起点接近 1。因此，WASE 初始时主要保留原始时域信号，避免频域增强在训练初期过度改变输入分布。随后，引入与样本无关的可学习基础频谱 $W_{\text{base}} \in \mathbb{R}^{N \times K}$ ，并与样本自适应滤波器 A 复合，得到完整频域系数。频域表示经过滤波后再通过逆傅里叶变换回到时域：

$$W = W_{\text{base}} \odot A, Z = Z \odot W, X = \text{irFFT}(Z)^\top \in \mathbb{R}^{B \times L \times N} \quad (7)$$

其中， W 表示基础频谱与自适应滤波器复合后的频域系数。 W_{base} 表示可学习基础频谱。 Z 表示滤波后的频域表示。 X 表示由 Z 经过逆傅里叶变换得到的时域序列。 $\text{irFFT}(\cdot)$ 表示实值快速傅里叶逆变换。 $(\cdot)^\top$ 表示时间维和变量维的转置操作。

最终，WASE 利用残差门 r 在原始时域信号和滤波后时域信号之间进行软融合，并通过 PPU 标量控制整体注入强度：

$$X_f = r \odot X^{(1)} + (1 - r) \odot X, X^{(2)} = X^{(1)} + \gamma_{\text{wase}} (X_f - X^{(1)}) \quad (8)$$

其中， X_f 表示残差门混合后的中间信号。 $X^{(2)}$ 表示 WASE 输出张量。 r 表示残差混合门。 X 表示频域滤波后回到时域的序列。 $\gamma_{\text{wase}} \in \mathbb{R}$ 表示零初始化的可学习残差系数。

当 $\gamma_{\text{wase}} = 0$ 时，WASE 退化为恒等映射，输出与输入保持一致。随着训练进行， γ_{wase} 逐步更新，样本依赖的频谱响应开始参与模型优化。通过这种方式，WASE 不是固定放大某一类频率，而是根据样本上下文决定不同频率成分的保留或调节程度，从而提升模型对晴天周期

结构和复杂天气短时扰动的适应能力。




Figure 3.The structure of Weather-Aware Spectral Enhancement (WASE)

2.2.3 Depthwise-Separable Convolution(DSC)

光伏功率在分钟到小时尺度上常出现剧烈的短程波动，例如云遮挡导致的瞬时功率跌落、阵风冷却带来的 1–3 h 爬升、以及温度跳变引起的局部斜率变化，这些都决定了短期预测中"局部斜率"与"爬坡时序"的拟合质量。iTransformer 将每个变量的历史序列视为一个变量 token，有利于捕获变量之间的依赖关系，但这种反转建模方式可能弱化局部变量之间的短期依赖。对于光伏功率预测而言，短时间内的辐照变化、温度滞后和功率爬坡过程往往包含重要的局部动态信息。为补充这一部分信息，本文在 WASE 之后引入轻量级深度可分离卷积模块 DSC，对每个变量沿时间维进行局部卷积增强。

DSC 的输入为 $X \in \mathbb{R}^{B \times L \times N}$ ，将它的时间维和变量维互换，得到 $X^{(2)\top} \in \mathbb{R}^{B \times N \times L}$ 。对于每个卷积核长度 $k \in \mathcal{K}_{\text{dsc}} = \{3, 5, 7\}$ ，DSC 分别执行按变量分组的深度卷积，公式表示为：

$$D_k = \text{GELU}(\text{DWConv}^{(k)}(\text{top}(X^{(2)\top}))) \in \mathbb{R}^{B \times N \times L} \quad (9)$$

其中， D_k 表示卷积核长度为 k 时提取到的局部时序特征。 $\text{DWConv}^{(k)}(\cdot)$ 表示核长为 k 的深度卷积。 $\mathcal{K}_{\text{dsc}}$ 表示 DSC 中使用的卷积核集合。 $X^{(2)\top}$ 表示由 $X^{(2)}$ 转置得到的张量。 $\text{GELU}(\cdot)$ 表示非线性激活函数。输出 D_k 的形状与 $X^{(2)\top}$ 保持一致。

随后将三个核的输出沿通道轴拼接并通过逐点卷积重组通道，再与转置后的输入做残差连接，公式表示为：

$$D \leftarrow \text{bigl}[D_3, D_5, D_7] \text{in} \mathbb{R}^{B \times 3N \times L}, \quad Y_{\text{dsc}} \leftarrow X^{(2)\top} + \text{Dropout}(\text{PWConv}(D)) \text{in} \mathbb{R}^{B \times 3N \times L} \quad (10)$$

其中， D 表示三个卷积尺度下局部特征的拼接结果。 $[D_3, D_5, D_7]$ 表示沿通道维进行拼接。 $\text{PWConv}(\cdot)$ 表示逐点卷积。 $\text{Dropout}(\cdot)$ 表示随机失活操作。 Y_{dsc} 表示 DSC 内部带残差连接的局部增强表示。

在该设计中， PWConv 的权重与偏置整层零初始化，使 DSC 内部增强项在训练初始阶段不改变输入特征分布。该设置是 PPU 在 DSC 中的一种实现形式。最后，将 Y_{dsc} 转回 $[B, L, N]$ 形状，并通过 PPU 标量进行整体残差注入，公式表示为：

$$X^{(3)} \leftarrow X^{(2)} + \gamma_{\text{dsc}} \text{bigl}(Y_{\text{dsc}}^{\top} - X^{(2)} \text{in} \mathbb{R}^{B \times 3N \times L} \quad (11)$$

其中， $X^{(3)}$ 表示 DSC 输出张量。 $\gamma_{\text{dsc}} \in \mathbb{R}$ 表示零初始化的可学习标量。 $Y_{\text{dsc}}^{\top}$ 表示将 DSC 内部输出转回原始输入维度后的结果。 $X^{(2)}$ 表示 DSC 的输入张量。

当 $\gamma_{\text{dsc}} = 0$ 时，DSC 输出与 WASE 输出保持一致。随着训练推进，DSC 学习到的局部增强项逐步参与模型优化。WASE 与 DSC 分别从频域和局部时域补充输入表示：前者关注不同天气状态下频率成分的自适应调节，后者关注变量内部短时斜率和局部爬坡过程的补强，二者共同提升进入 backbone 前输入序列的物理一致性和局部动态表达能力。

2.3 iTransformer Backbone

重构后的序列 $X^{(3)}$ 被送入 iTransformer backbone，从而被嵌入为一个变量级 token，并在变量维度上执行注意力计算。对于光伏功率预测任务而言，辐照度、温度、风速和历史功率等变量之间存在明显的耦合关系，变量级 token 有助于模型更直接地刻画跨变量依赖。基于这一特点，本文沿用 iTransformer 作为 PPU-Former 的基础预测主干，并在其变量级注意力子层中进一步引入物理引导机制。Backbone 主要由 RevIN-lite 归一化、Inverted Embedding、encoder block 和线性预测头组成，其整体结构如图 4 所示。

Figure 4. The architecture of the iTransformer backbone.

输入张量 $X^{(3)}$ 进入 backbone 前，首先沿时间维进行按样本、按变量的 z-score 归一化，以减弱不同变量量纲和分布差异对模型训练的影响：

批注 [1]：这一章节介绍 iTransformer，而不是介绍反转注意力机制。把仿画的 iTransformer 结构图插入这一章节，然后系统介绍下。你的 PGIA 已经作为“反转”来宣传，这里模型内部的 backbone 不需要大篇幅介绍

批注 [2]：直接说 X^3 是什么

批注 [3]：我至少见过 4 次这种表述

批注 [4]：注意细节

$$\mu = \frac{1}{L} \sum_{t=1}^L X_{:,t,:}^{(3)}, s^2 = \frac{1}{L} \sum_{t=1}^L (X_{:,t,:}^{(3)} - \mu)^2, \mathcal{X} = \frac{X^{(3)} - \mu}{\sqrt{s^2 + \epsilon}} \quad (12)$$

其中, $X^{(3)}$ 表示经过 PSG、WASE 和 DSC 输入重构后的序列; B 表示 batch size; L 表示历史输入窗口长度; N 表示输入变量总数; $\mu \in \mathbb{R}^{B \times 1 \times N}$ 表示沿时间维计算得到的均值; $s^2 \in \mathbb{R}^{B \times 1 \times N}$ 表示沿时间维计算得到的方差; s 表示标准差; $\mathcal{X}$ 表示归一化后的输入张量; ϵ 表示用于数值稳定的极小常数; t 表示历史窗口中的时间步索引。归一化过程中保存的 μ 和 s 将在预测输出阶段用于反归一化。

随后, 将 $\mathcal{X}$ 的时间维和变量维互换, 得到 $\mathcal{X}^T \in \mathbb{R}^{B \times N \times L}$ 。每个变量的历史序列通过线性映射被嵌入为 d 维 token, 得到初始变量级表示:

$$H_0 = \text{Linear}_{L \rightarrow d}(\mathcal{X}^T) \in \mathbb{R}^{B \times N \times d} \quad (13)$$

其中, H_0 表示 Inverted Embedding 后得到的初始变量 token 表示; $\text{Linear}_{L \rightarrow d}(\cdot)$ 表示从历史窗口长度 L 到模型嵌入维度 d 的线性映射; d 表示模型隐藏维度; $\mathcal{X}^T$ 表示转置后的归一化输入张量。

若启用时间协变量, 则时间编码 token 会与观测变量 token 一同送入 Inverted Embedding。编码器堆栈由 L_e 个 encoder block 串联组成。每个 encoder block 包含注意力子层和前馈网络子层, 并采用残差连接、Dropout 和 LayerNorm, 其计算过程表示为:

$$H'_\ell = \text{LN}(\text{Drop}(\text{Attn}_\ell(H_{\ell-1}))), H_\ell = \text{LN}(\text{Drop}(\text{FFN}_\ell(H'_\ell))) \quad (14)$$

其中, ℓ 表示 encoder 层索引, 且 $\ell = 1, \dots, L_e$; L_e 表示 encoder 层数; $H_{\ell-1}$ 表示第 ℓ 层的输入 token 表示; H'_ℓ 表示注意力子层输出后、进入前馈网络前的中间表示; H_ℓ 表示第 ℓ 层 encoder 的输出; $\text{Attn}_\ell(\cdot)$ 表示第 ℓ 层注意力子层; $\text{FFN}_\ell(\cdot)$ 表示第 ℓ 层前馈网络; $\text{LN}(\cdot)$ 表示 LayerNorm; $\text{Drop}(\cdot)$ 表示 Dropout。

在 vanilla Transformer 中, $\text{Attn}_\ell(\cdot)$ 采用标准缩放点积注意力。本文保持 FFN、LayerNorm、Dropout 和残差连接不变, 仅将该注意力子层替换为后文提出的 PGIA, 使样本物理状态能够直接参与变量级注意力分配。

经过 L_e 层 encoder 后, 最终 token 表示 H_{L_e} 通过共享线性预测头映射为未来 H 个时间步的多变量预测结果:

$$Y_{\text{full}} = \text{Linear}_{d \rightarrow H}(H_{L_e}) \in \mathbb{R}^{B \times (N+n_t) \times H} \quad (15)$$

其中, Y_{full} 表示线性预测头输出的完整预测结果; $\text{Linear}_{d \rightarrow H}(\cdot)$ 表示从隐藏维度 d 到预测步长 H 的线性映射; H_{L_e} 表示最后一层 encoder 的输出; H 表示预测步长; $N + n_t$ 表示变量 token 与时间协变量 token 的总数。当未启用时间协变量时, 可视为 $n_t = 0$ 。

预测阶段只保留目标变量 Active_Power 对应的输出通道, 并利用公式 (12) 中保存的统计量进行反归一化, 得到最终预测结果:

$$Y = (s \odot Y_{\text{full}})_{:,j_Y} + \mu_{:,j_Y} \quad (16)$$

其中, Y 表示最终目标变量预测结果; $j_Y = \{4\}$ 表示目标变量 AP 在变量轴上的索引; $\odot$ 表示逐元素乘法; s 和 μ 表示公式 (12) 中保存的逐样本、逐变量统计量; Y_{full} 表示线性预测头输出的完整预测结果。

实际计算中, 时间协变量 token 不作为预测目标, 仅保留观测变量中的目标通道与训练损

失对接。

2.4 Progressive Physics Unlocking (PPU)

批注 [5]: 反转

将多个物理增强模块同时接入已有 backbone 时, 训练初期容易出现输入分布和注意力分布的突然变化。对于 PPU-Former 而言, PSG、WASE、DSC 和 PGIA 分别作用于输入幅值、频域响应、局部时序和变量级注意力。如果这些模块在随机初始化后立即强作用于 backbone, 模型需要同时适应多个新增扰动, 可能导致优化过程不稳定, 也会削弱各模块贡献的可解释性。为缓解这一问题, 本文提出渐进式物理解锁策略 PPU, 作为所有新增物理增强模块共享的统一部署机制, 其作用机理如图 5 所示。

PPU 的核心思想是使新增物理模块从“不改变原模型计算”的状态开始训练, 再通过可学习门控逐步释放其作用。给定一个待注入 backbone 的物理增强模块 $f_{\text{module}}(\cdot)$, PPU 采用可学习标量门 γ 对原信号和增强信号进行线性组合:

$$\mathbf{x}_{\text{out}} = \mathbf{x}_{\text{in}} + \gamma \cdot (f_{\text{module}}(\mathbf{x}_{\text{in}}) - \mathbf{x}_{\text{in}}), \gamma|_{t=0} = 0 \quad (17)$$

其中, $\mathbf{x}_{\text{in}}$ 表示物理增强模块的输入; $\mathbf{x}_{\text{out}}$ 表示物理增强模块的输出; $f_{\text{module}}(\cdot)$ 表示待接入的物理增强函数; $\gamma \in \mathbb{R}$ 表示可学习标量门; $t = 0$ 表示训练初始化时刻。

当 $\gamma = 0$ 时, 公式 (17) 退化为 $\mathbf{x}_{\text{out}} = \mathbf{x}_{\text{in}}$, 对应物理增强模块在训练初始阶段不会改变 backbone 的计算结果。随着训练过程中预测损失的反向传播, γ 由零初始化状态逐步更新, 使该模块的增强项逐渐参与模型优化。这样, PPU-Former 可以在训练初期保持与 vanilla iTransformer 接近的稳定起点, 同时在训练过程中逐步学习是否需要以及如何使用各类物理增强信息。

对于 PSG、WASE 和 DSC 这类作用于特征表示的模块, PPU 体现为零初始化的残差标量门, 例如 γ_{psg} 、 γ_{wase} 和 γ_{dsc} 。对于 PGIA 这类作用于 attention logits 的模块, PPU 不再额外引入标量门, 而是通过将物理偏置网络的末层权重和偏置零初始化, 使物理偏置在训练初始阶段为零, 从而保证 PGIA 起步时退化为标准反转注意力。

PPU 具有两个直接作用。第一, 它提供恒等起步性, 使新增物理增强路径在训练开始时不会破坏 backbone 的初始计算流程。第二, 它提供渐进释放性, 使各物理增强项只能在训练过程中通过预测损失的梯度更新逐步发挥作用。训练结束后, 各模块对应的 γ 取值可作为观察模块是否被有效激活的辅助指标。

Figure 5. The illustration of Progressive Physics Unlocking (PPU) strategy.

2.5 物理引导反转注意力 PGIA (Physics-Guided Inverted Attention)

光伏功率的变化受到太阳几何、辐照条件、气象扰动和历史功率状态的共同影响。不同变量之间的关系并非在所有物理状态下都保持一致。例如, 晴天白天时, 太阳几何、辐照强度和有功功率之间通常具有较强耦合; 夜间或低辐照阶段, 辐照与功率之间的有效耦合明显减弱; 在多云或过云条件下, 辐照与功率的关系又会受到短时扰动影响。标准 iTransformer 虽然能够通过变量级注意力建模跨变量依赖, 但其注意力权重主要由数据相关性驱动, 物理先验

通常只作为输入特征参与建模，并未直接参与变量交互过程。

为使物理状态能够直接影响变量级注意力分配，本文提出物理引导反转注意力 PGIA。PGIA 用向量描述当前输入样本的太阳几何、晴空程度和昼夜状态，并在每层 attention 的 pre-softmax logits 中加入可学习偏置。通过这种方式，模型不仅能够从数据中学习变量间依赖，还可以根据当前物理状态对注意力分布进行差异化调整。PGIA 替换公式 (14) 中的 $\text{Attn}_\ell(\cdot)$ 子层，FFN、LayerNorm、残差连接以及 backbone 的主要超参数保持不变，其结构如图 6 所示。

为生成注意力偏置的条件信号，PGIA 从原始输入张量 X 中提取与昼夜状态、晴空程度和气象调节相关的物理量，共四个维度，并沿时间维取平均，得到样本级物理摘要：

$$\phi = \frac{1}{L} \sum_{t=1}^L X_{:,t, \mathcal{I}_{\text{cond}}} \in \mathbb{R}^{B \times 4}, \mathcal{I}_{\text{cond}} = \{5, 9, 11, 16\} \Leftrightarrow \{\theta_z, AM, k_t, I_{\text{day}}\} \quad (18)$$

其中， ϕ 表示样本级物理摘要向量； X 表示输入重构之前的原始输入张量； $\mathcal{I}_{\text{cond}}$ 表示用于生成物理摘要的条件通道索引集合； θ_z 表示太阳天顶角； AM 表示气团数； k_t 表示晴空指数； I_{day} 表示昼夜指示变量； B 表示 batch size； L 表示历史输入窗口长度。

这里将 ϕ 从原始输入 X 中提取，目的是保持“物理状态生成注意力偏置”这一路径的独立性。这样，PGIA 使用的是样本原始物理状态，从而避免不同物理增强模块之间的作用路径混淆。当前第 ℓ 个 encoder 层的输入为 $H_{\ell-1} \in \mathbb{R}^{B \times N_{\text{tot}} \times d}$ ，其中 $N_{\text{tot}} = N + n_t$ 表示变量 token 与时间协变量 token 的总数。PGIA 首先按照标准多头注意力方式生成 query、key 和 value：

$$Q_\ell, K_\ell, V_\ell = W_\ell^Q H_{\ell-1}, W_\ell^K H_{\ell-1}, W_\ell^V H_{\ell-1} \in \mathbb{R}^{B \times h \times N_{\text{tot}} \times d_h}, d_h = d/h \quad (19)$$

其中， Q_ℓ 、 K_ℓ 和 V_ℓ 分别表示第 ℓ 层注意力中的 query、key 和 value； W_ℓ^Q 、 W_ℓ^K 和 W_ℓ^V 表示第 ℓ 层对应的可学习投影矩阵； $H_{\ell-1}$ 表示第 ℓ 层 encoder 的输入； h 表示注意力头数； d_h 表示单个注意力头的维度； d 表示模型隐藏维度。

在标准缩放点积注意力中，attention logits 由 $Q_\ell K_\ell^T / \sqrt{d_h}$ 计算得到。PGIA 在此基础上加入由物理摘要 ϕ 生成的物理偏置：

$$\text{scores}_\ell = \frac{Q_\ell K_\ell^T}{\sqrt{d_h}} + \text{PhysBias}_\ell(\phi) \quad (20)$$

其中， scores_ℓ 表示加入物理偏置后的注意力 logits； $Q_\ell K_\ell^T / \sqrt{d_h}$ 表示标准缩放点积注意力 logits； K_ℓ^T 表示 key 矩阵的转置； $\text{PhysBias}_\ell(\phi)$ 表示由物理摘要 ϕ 生成的第 ℓ 层物理注意力偏置。

具体而言， $\text{PhysBias}_\ell(\cdot)$ 由两层 MLP 实现，将四维物理量映射为变量间注意力偏置：

$$\text{PhysBias}_\ell(\phi) = W_\ell^{(2)} \text{GELU}(W_\ell^{(1)} \phi + b_\ell^{(1)}) + b_\ell^{(2)} \quad (21)$$

其中， $W_\ell^{(1)}$ 和 $W_\ell^{(2)}$ 表示第 ℓ 层物理偏置 MLP 的可学习权重矩阵； $b_\ell^{(1)}$ 和 $b_\ell^{(2)}$ 表示对应的可学习偏置项； $\text{GELU}(\cdot)$ 表示 GELU 非线性激活函数。该 MLP 的输出首先对应前 N 个变量 token 之间的 $N \times N$ 物理偏置矩阵，随后根据 token 总数扩展到与 scores_ℓ 一致的维度。

在 PGIA 中，末层权重 $W_\ell^{(2)} \in \mathbb{R}^{N^2 \times h_{pb}}$ 与偏置 $b_\ell^{(2)} \in \mathbb{R}^{N^2}$ 整层零初始化。其中， h_{pb} 表示物理偏置 MLP 的隐藏维度。该设置是 PPU 在 PGIA 中的具体实现，使训练初始阶段 $\text{PhysBias}_\ell(\phi) = 0$ ，从而使 PGIA 退化为标准反转注意力。生成的物理偏置随后被扩展到与 attention logits 相同的维度，并加到变量级注意力计算中。

加入物理偏置后，后续 softmax 和 attention 输出过程与标准多头注意力保持一致：

$$A_\ell = \text{softmax}(\text{scores}_\ell), \text{Attn}_\ell(H_{\ell-1}; \phi) = W_\ell^O (A_\ell V_\ell) \tag{22}$$

其中， A_ℓ 表示加入物理偏置后的注意力权重矩阵； $\text{softmax}(\cdot)$ 表示沿注意力计算维度进行归一化； $\text{Attn}_\ell(H_{\ell-1}; \phi)$ 表示第 ℓ 层 PGIA 注意力输出； W_ℓ^O 表示多头注意力的输出投影矩阵； V_ℓ 表示第 ℓ 层 value 矩阵。

PGIA 并不是用物理先验替代数据驱动注意力，而是在 softmax 之前对变量间关系进行物理状态引导。通过该设计，模型仍然保留 iTransformer 从数据中学习变量依赖的能力，同时能够根据昼夜状态、晴空指数和气象扰动对注意力分布进行调整。

第三章 Case study

3.1 Dataset Description

本文采用的数据来源于澳大利亚 Alice Springs 地区 DKASC 中 Site-3 A of the Yulara solar system located near Uluru, Australia，包含光伏电站运行过程中的气象观测数据和有功功率数据，时间范围为 2017 年 1 月 1 日至 2019 年 12 月 31 日共 3 个完整自然年的运行数据，数据时间分辨率为每小时一帧，预测目标为未来时刻的有功功率 Active Power（AP）。原始数据中包含多类气象观测变量和运行状态变量。本文首先对候选气象变量进行统计分析，并在后续预处理阶段通过 Pearson 相关性分析进一步筛选输入变量。最终用于模型建模的实测变量包括全球水平辐照度 GHR、总辐照传感器 Py、风速 WS、温度 TP1 以及历史有功功率 AP。除站点实测变量外，本文进一步根据站点经纬度和时间戳解析生成 12 维太阳物理先验，包括太阳天顶角、太阳方位角、时角、太阳赤纬角、太阳高度角、气团数、晴空全球水平辐照度、晴空指数、地外太阳辐照度、日长、太阳正午时刻以及昼夜指示变量。最终构造的模型输入共包含 17 个变量，即 4 个气象观测变量、1 个历史目标变量 AP 和 12 个解析式物理先验变量，其特征缩写对照关系如表 1 所示。

Table 1 Feature Abbreviation Reference Table

raw data	Abbreviation
Pyranometer_1	Py
Wind_Speed	WS
Temperature_Probe_1	TP1
Active_Power	AP
Solar zenith angle	θ_z
Solar Azimuth Angle	γ_s
Hour Angle	ω
Solar Declination	δ
Solar Altitude Angle	α_s
Air Mass	AM
Clear-sky Global Horizontal Irradiance	GHIcs
Clear-sky Index	kt

Extraterrestrial Irradiance	I0
Day Length	DL
Solar Noon	tnoon
Day or Night Indicator	Iday

为初步了解数据分布情况，本文对原始候选变量进行统计描述，统计量包括均值、标准差、最小值、四分位数和最大值，结果如表 2 所示。

Table 2 Statistical row description of each feature in the dataset


Feature	Unit	mean	std	min	25%	50%	75%	max
AEDR	kWh	106446.35	46325.97	25599.58	65686.40	105980.11	147559.31	174105.73
WS	m/s	2.41	4.36	-25.45	1.15	1.96	2.85	60.32
WT	° C	23.68	11.75	-25.94	16.11	23.23	30.09	105.43
GHR	W/m2	261.92	387.08	-2343.4	-3.4	10.21	539.10	2902.39
WD	degree	163.67	89.56	-1162.7	135.01	154.85	193.59	1030.58
WDR	mm	0	0	0	0	0	0	0.08
MWS	m/s	4.29	5.82	-29.98	2.11	3.69	5.53	92.6
APs	hpa	957.52	6.23	927.87	953.19	957.43	961.75	1002.21
Py	W/m2	283.04	418.67	-2212.8	-3.2	12.88	590.28	3263.87
TP1	° C	45.13	17.65	-53.16	35.55	40.78	50.87	295.75
TP2	° C	45.05	17.54	-69.83	35.41	40.68	51.85	328.04
AP	kW	4.98	6.67	-0.04	-0.02	0.08	10.8	21.2

从统计结果可以看出，GHR 与 Py 具有明显的昼夜波动特征，其标准差较大，说明辐照类变量随日照状态变化明显；AP 呈现“夜间接近零、白天升高”的分布特点，符合光伏功率输出的基本规律。GHR、WS、TP1 与功率波动具有显著物理相关性，将在后续相关性分析与特征建模中重点考虑。

3.2 Data Preprocessing

为保证输入数据质量，并减少冗余气象变量对模型训练的干扰，本文在模型训练前对 DKASC Site-3A 原始数据进行统一预处理。预处理过程主要包括时间对齐、异常修复、Pearson 相关性分析、物理先验生成、变量拼接、标准化处理和滑动窗口样本构造。

原始数据按照时间戳进行升序排列，并统一对齐到小时级时间分辨率。本文采用连续历史序列作为模型输入，在样本生成之前，对时间索引进行检查和修正，保证输入序列在时间维度上连续。在异常修复阶段，对于短时间缺失或孤立异常点，采用线性插值进行修复；对于连续异常时间较长的片段，采用三点 Lagrangian 插值进行补全。完成基础清洗后，基于修复后的原始候选气象变量计算 Pearson 相关系数，用于分析各气象变量与 AP 之间的线性相关程度。相关性热力图如图 6 所示。



随后, 采用 NREL SPA 太阳位置算法和 Ineichen-Perez 晴空模型计算太阳天顶角 θ_z 、太阳方位角 γ_s 、时角 ω 、太阳赤纬角 δ 、太阳高度角 α_s 、气团数 AM 、晴空全球水平辐照度 GHI_{CS} 、晴空指数 k_t 、地外太阳辐照度 I_0 、日长 DL 、太阳正午时刻 t_{noon} 和昼夜指示变量 I_{day} 。将 Pearson 筛选后的 4 个气象变量、历史 AP 和全部 12 个物理先验沿变量轴拼接, 形成 17 维多变量输入序列。在标准化处理时, 仅在训练集上估计各变量的 z-score 统计量, 并将固定后的统计量应用于验证集和测试集, 以避免测试集分布信息泄漏到训练过程。最后, 采用滑动窗口方式构造监督学习样本。每个样本由一段连续历史输入序列和对应的未来 AP 标签组成。

PPU-Former 基于 Ubuntu 20.04 操作系统, Python 版本为 3.8, 深度学习框架为 PyTorch 2.0.0, CUDA 版本为 11.8。实验硬件 GPU 为 NVIDIA RTX 3090, 显存容量为 24GB; CPU 为 AMD EPYC 7642 48-Core Processor, 分配 20 vCPU; 内存容量为 90 GB。

优化设置方面, 所有模型在可适用范围内采用统一训练配置。优化器采用 Adam, batch size 设置为 32, 初始学习率为 2×10^{-4} , 学习率衰减策略采用 type2。最大训练轮数设置为 50 epoch, 并以验证集 MSE 为监控指标启用 patience=8 的 early stopping, 以减少过拟合。各模型的超参数配置如下表 4 所示:

Model	Hyperparameter
PPU-Former	seq_len=168, pred_len=24, d_model=128, n_heads=8, e_layers=2, d_ff=256, dropout=0.1, embed=timeF, use_psg=1, use_wase=1, use_dsc=1, use_pgia=1, wase_hidden=64
iTransformer	seq_len=168, pred_len=24, d_model=128, n_heads=8, e_layers=2, d_ff=256,

	dropout=0.1, embed=timeF
Transformer	seq_len=168, label_len=48, pred_len=24, d_model=128, n_heads=8, e_layers=2, d_layers=1, d_ff=256, dropout=0.1
Informer	seq_len=168, pred_len=24, d_model=128, n_heads=8, e_layers=2, d_ff=256, factor=1, dropout=0.1
PatchTST	seq_len=168, pred_len=24, patch_len=16, stride=8, d_model=128, n_heads=8, e_layers=2, d_ff=256, dropout=0.1
LSTM	hidden_size: 64, dropout: 0.1
FED	nb_filters: 64, kernel_size: 2, dropout: 0.2, LSTM_units: 128
Auto	

3.4 Evaluation Metrics

为综合评估预测性能，本文采用以下三种主流评估指标：
均方根误差（Root Mean Squared Error, RMSE）

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

平均绝对误差（Mean Absolute Error, MAE）

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

决定系数（Coefficient of Determination, R^2 ）

$$R^2 = 1 - \frac{\sum_{i=1}^N (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

其中 $\hat{y}_i$ 表示第*i*个时间步的预测值， y_i 为真实值， $\bar{y}$ 为平均值， N 为总时间步数。上述指标可全面反映模型在预测精度、稳定性与相对误差控制方面的性能表现^[30]。